



Pré-Processamento de Dados: Jornada para Qualidade

Uma análise completa das etapas essenciais para preparar dados de qualidade, desde identificação de problemas até transformações e engenharia de features, resultando em um dataset robusto e pronto para modelagem.

A stylized illustration on the left side of the slide. It features a person wearing a headset and holding a device, standing on a light-colored ground. Surrounding them are various floating icons and charts: a donut chart, a line graph with a sun, a bar chart, a checkmark in a circle, a play button, a lightbulb, and several smaller bar and line charts. The background is a mix of light blue and yellow, with some abstract shapes and a small airplane icon.

Problemas Corrigidos

No início da análise, encontramos alguns problemas no conjunto de dados.

Primeiro, havia valores faltantes nas colunas `description_length` e `shares_count`, somando um total de **216 valores ausentes**. Esses valores foram preenchidos com média ou mediana, dependendo da distribuição dos dados.

→ Análise de Outliers

Detectados 14 outliers na coluna `duration_minutes` usando intervalo interquartílico. Limitamos valores em vez de remover, preservando dados.

→ Verificação de Duplicatas

Nenhuma duplicata encontrada. Dataset manteve integridade completa sem perda de informação.

Transformações de Distribuição (Skewness)

Em seguida, verificamos a distribuição das colunas numéricas.







Encontramos alta assimetria em duas variáveis: **duration_minutes** com skew de **1.03** e **total_views** com skew de **2.08**.


Transformação Log1p

Aplicada para reduzir cauda longa e centralizar distribuição, permitindo melhor compreensão das relações entre variáveis.

Resultado

Distribuição mais equilibrada e normalizada, otimizando desempenho de modelos de aprendizado de máquina.





Features Criadas

Também criamos duas novas variáveis para melhorar o poder preditivo do modelo.




Engagement_Sum

Soma likes, comentários, compartilhamentos e adições em playlists. Representa engajamento total do vídeo com correlação de **0.055** com visualizações.



Title_Desc_Ratio

Proporção entre tamanho do título e descrição. Correlação de **0.043** com total de views — títulos mais longos atraem ligeiramente mais atenção.



Resultado Final

Depois de todas as etapas, o dataset ficou totalmente limpo e pronto para modelagem.

2.520

Linhas Mantidas

Sem perdas — preservação total de observações

44

Colunas Finais

De 22 originais (novas variáveis + one-hot encoding)

0

Valores Faltantes

Dataset 100% completo e robusto

O conjunto original teve suas variáveis numéricas normalizadas, outliers tratados adequadamente, e o scaler foi salvo para uso futuro em novos dados. Concluímos o pré-processamento com sucesso.



Obrigado!

Agradecemos o seu tempo e atenção !