

Etapas 3 & 4: Modelos Baseline e Avançado – Previsão de Desempenho de Vídeos do YouTube

1. Contexto

Nosso objetivo é prever o desempenho final de vídeos publicados no YouTube com base em suas características iniciais, como CTR, tempo médio assistido, duração e engajamento. Essa previsão permite identificar vídeos com potencial de baixa performance antes de receberem muitas impressões, possibilitando ajustes de título, thumbnail e estratégia de publicação.

2. Dados

- Dataset: students_clean
- Amostras: 2.520 vídeos
- Target: total_views
- Features: ~45 variáveis incluindo CTR, watchtime, likes, duração, categoria, horário de upload, etc.
- Divisão: 60% treino / 20% validação / 20% teste

3. Metodologia

Implementamos uma Regressão Linear como modelo baseline (Etapa 3), buscando a relação linear entre as features e o total de visualizações.

4. Resultados

Métricas de Performance

Treino:

- R^2 : 0.8364
 - RMSE: 0.4113
 - MAE: 0.2201
- ##### **Validação:**
- R^2 : 0.8869
 - RMSE: 0.3369
 - MAE: 0.2138

Interpretação: O modelo avançado explica até 88% da variação nas visualizações finais ($R^2 = 0.8869$). O erro médio é baixo (RMSE ≈ 0.33 na validação), indicando excelente precisão e forte capacidade preditiva.

Análise de Overfitting: A diferença entre treino e validação foi: $|0.8364 - 0.8869| = 0.0505$. Como está abaixo de 0.10, o modelo generaliza bem e não apresenta sinais de overfitting.

Predições vs Valores Reais: As previsões se alinham bem com os valores reais, formando uma dispersão concentrada ao redor da linha diagonal. Apenas vídeos virais aparecem como outliers, o que é esperado em dados de YouTube.

Variáveis Mais Importantes:

- avg_watch_time: forte impacto positivo
- ctr: forte impacto positivo
- likes: impacto moderado
- duration_sec: impacto variável, podendo ajudar ou prejudicar dependendo do contexto

Insight: Retenção (watchtime) e CTR são os maiores preditores de alcance, refletindo exatamente o funcionamento do algoritmo do YouTube.

5. Conclusões**O que Funcionou:**

- R^2 alto (0.8869)
 - Baixo erro (RMSE $\approx$ 0.33)
 - Modelo sem overfitting
 - Variáveis importantes fazem sentido prático
- Limitações:
- Vídeos virais continuam sendo outliers naturais
 - Relações complexas podem exigir mais tuning
 - Encoding de categorias pode ser aprimorado

Equipe: [Nicole, Rayssa, Kauê e José Augusto]

Data: 17/11/2025

Código: <https://github.com/rKafevas/ML-Youtube/>